

BAC Learning Lab Engineer Nivel 2 (Aula Invertida)

Versión: 1.1

Fecha creación: Marzo 2026

Última actualización: 07/06/2026

Audiencia: Data Engineers

Tabla de Contenidos

1. [Material de Apoyo](#)
 2. [Reglas](#)
 3. [Reto 1](#)
 4. [Reto 2](#)
 5. [Reto 3](#)
 6. [Recomendaciones](#)
 7. [Fuentes de Datos para Pruebas](#)
-

Material de Apoyo

Udemy Business BAC

Se recomienda el curso [Databricks y Apache Spark para Big Data de Cero a Experto](#), específicamente en las secciones:

- Sección 2: Introducción a Spark
- Sección 3: Spark DataFrames y Apache Spark SQL
- Sección 3: Funciones Avanzadas de Spark

Microsoft Learning:

- [Introducción a Azure Databricks y Apache Spark](#)
- [Apache Spark en Azure Synapse Analytics](#)

YouTube:

- [¿Qué es Apache Spark?](#)
- [Trabajando con PySpark en Databricks para Datos](#)

Objetivos por Aprender:

- Maximizar el uso de los Dataframes con Spark
- Aplicar funcionalidades similares a SQL con Dataframes de Spark: SELECT, WHERE, JOIN, GROUP BY, HAVING, ORDER BY, UNION, DML (INSERT, UPDATE, DELETE)
- Aprender a cargar datos de archivos como json, csv y parquets a un Dataframe
- Saber cómo leer solo los archivos según su fecha de última actualización o bajo alguna lógica puntual

- Saber cómo leer varios archivos en un mismo DataFrame
 - Manejar Parámetros desde los Notebooks de Databricks
-

Desafío

Reglas

A continuación se definen las reglas que se deben seguir para la realización del desafío del BLL Engineer:

1. El desafío debe ser resuelto y entregado máximo al **05 de Julio del 2026**.
2. Cada Participante debe grabar un video compartiendo el escritorio, donde se explique como se desarrollo los notebooks y se ejecuten los mismos. Los notebooks deben ejecutarse de forma exitosa.
3. El video del punto anterior debe ser grabado durante los días indicados en el punto numero 1 de estas reglas.
4. El vídeo del punto 2 no debe exceder los 15 minutos.
5. Adicional al video, debe adjuntar en el chat de la reunión que le estara llegando, el notebook o al menos el código del notebook.
6. Para la realización del Desafío solo se pueden utilizar:
 - **Databricks Free Edition** únicamente, puede usar la laptop personal o laboral.
 - Si la laptop laboral presenta algún problema de bloqueo, debe usar la personal.
7. El desafío debe ser realizado de forma totalmente individual.
8. Para este desafío el uso de **Spark SQL** queda prohibido, todo debe ser realizado únicamente con **PySpark** y **DataFrames de Spark**.

Reto 1

Debe proceder a descargar el archivo **rows.csv** que se encuentra en la ruta:

<https://health.data.ny.gov/api/views/jxy9-yhdk/rows.csv>.

El Notebook debe contener:

1. Todo el paso a paso de cómo descargó el archivo CSV.
2. Debe simular una medalla de bronce, con la creacion de un schema en el catalog **workspace** llamado **datalake** y los volúmenes necesarios para dar solución al ejercicio (por ejemplo **raw_data** y **bronze**).
3. Cargar el archivo CSV en el volumen **raw_data**.
4. Debe mover el archivo del punto 3 en la siguiente ruta, **/workspace/datalake/bronze/babys**, esto debe verse reflejado en el notebook.
5. Realice un análisis con esos datos usando únicamente **DataFrames** y **PySpark**, el análisis debe mostrar como resultado el TOP 5 de Nombres de Bebés que más se repiten, se espera algo como esto:

Nombre Bebé	Cantidad Repetidos
ABC	#####
DEF	#####
HIJ	#####
KLM	#####
NRS	#####

Reto 2

Utilizando los archivos CSV que se encuentran dentro del archivo zip "[Nivel_2.zip](#)", realice el siguiente análisis:

Obtenga la sumatoria total de las compras y el promedio de las compras agrupadas por la provincia donde viven los clientes, adicionalmente, ordene el resultado de tal manera que primero muestre la provincia donde viven los clientes que realizaron el total de compras mayor.

Reglas:

1. Los siguientes puntos deben quedar codificados en el notebook.
2. Debe descargar el archivo CSV llamado [Nivel_2.zip](#) y descomprimirlo.
3. A continuación, mueva todos los archivos CSV a la siguiente ruta:
[/workspace/datalake/bronze/sales](#).
4. Los siguientes archivos son de tipo Maestros: [Clientes](#) y [Cuentas](#).
5. Los siguientes archivos son de tipo Catálogo: [EstadosCuentas](#), [Provincia](#), [Canton](#) y [Distrito](#).
6. El siguiente archivo es Histórico (Incremental): [Compras](#) y [OrderDetail](#).
7. Configure el Notebook de Databricks para que reciba 2 parámetros (dbutils.widgets):
 - [fechaProceso](#) en formato YYYY-MM-DD = 2025-12-15
 - [diasCargar](#) en formato numérico entero.
8. Para cada archivo de tipo maestro y catálogo, solo se debe leer el archivo que contenga la fechaProceso brindada por parámetro, ahora bien, si el archivo con esa fechaProceso no existe, entonces debe leer el más reciente que haya en la medalla de Bronce. Importante: no debe "[quemar](#)" el nombre del archivo al momento de leerlo, debe manejar todo con variables o parámetros.
9. Para el archivo Histórico (Incremental), se debe leer únicamente los del día 1 al 10 de Diciembre 2025 de forma estricta. Importante: no debe "[quemar](#)" el nombre de los archivos al momento de leerlos, debe manejar todo con variables o parámetros.

El resultado esperado para este Reto es algo similar a lo siguiente:

Provincia	Sumatoria Total	Promedio
ABC	#####	#####
DEF	#####	#####
HIJ	#####	#####
KLM	#####	#####
NRS	#####	#####

Reto 3

Utilizando los mismos archivos descargados en el Reto 2 y aplicando la misma regla de lectura de datos según categoría de: **Maestros**, **Catálogos** e **Históricos**, obtenga el siguiente resultado:

Genere los datos agrupados por los diferentes Estados de Cuenta, por cada Estado, debe contabilizar cuántos registros hay, sin embargo, esto solo aplica para los Clientes que viven en Heredia, San Jose y Alajuela, además, que han hecho compras mayores o iguales a los 15,000.00 Colones. Se espera ver un resultado similar al siguiente:

Estados Cuenta	Cantidad Compras
ABC	#####
DEF	#####
HIJ	#####
KLM	#####
NRS	#####

Recomendaciones

1. Tome en cuenta las reglas que deben seguir los archivos .parquet, principalmente las reglas de nombrado de columnas, y sus valores o caracteres permitidos y no permitidos.
2. No se permite el uso de **Spark SQL**, todo debe ser realizado con **PySpark** y **DataFrames**.
3. Utilice variables y parámetros para la gestión de rutas y nombres de archivos, evitando valores "quemados".
4. Aproveche los recursos de aprendizaje recomendados para reforzar el uso de **PySpark** y **Databricks**.

Troubleshooting y FAQs

Error 1: Sin Acceso a Git (Azure DevOps)

Si al ingresar al Azure Data Factory (DFDWDEV) no tienes acceso al Git (DevOps) debes realizar los pasos en el siguiente manual.

Enlace: [Licencia para BLL Ingeniero de Datos - Ambiente Dev](#)

Error 2: Fuentes de Datos no estan Accesibles

Las fuentes de datos solo se pueden usar en ambiente de Desarrollo de BAC o en ambiente Personal.

Las fuentes se encuentran en un servidor On-Premises, por lo que en caso de presentar problemas favor indicarme, a Luis Picado, para que pueda revisar y dar solucion, pueden contactarme por al Teams.

Servidores:

```
Microsoft SQL Server
- Servidor: msql.luispicado.com
- Puerto: 51430
- Usuario: sql_userbll
- Password: bll.1234!
- Modo Encriptación: Opcional
- Trust Server Certificate = True
```

```
SFTP
- Host: sftp.luispicado.com
- Puerto: 51432
- Usuario: sftp_userbll
- Password: bll.1234!
```

```
IBM DB2
- Host: db2.luispicado.com
- Puerto: 551431
- Usuario: db2_userbll
- Password: bll.1234!
```

```
Apache File Server
- Web: http://data.luispicado.com
```

Error 3: APIs de Ayuda o para Pruebas

APIs:

- [Bank Holidays - API Catalogue \(www.api.gov.uk\)](http://www.api.gov.uk)
- [Developer Center / APIs | Biblioteca Abierta \(openlibrary.org\)](http://openlibrary.org)

Datasets en CSV de Kaggle:

- [100 Highest Paid Athletes of the World \(kaggle.com\)](#)
- [UAE Real Estate 2024 Dataset \(kaggle.com\)](#)
- [Airline Flight Routes in The US \[1993-2024\] \(kaggle.com\)](#)
- [Global Super Store Dataset \(kaggle.com\)](#)